



① 冻结模型与完整输入



② 模态级遮蔽

模态 m 的观测掩码整体置零、输入置零
得到 $p^{(-m)}(\hat{y})$ 与 $\hat{r}^{(-m)}$
计算 Δ_m^{cls} 、 Δ_m^{int} 并样本内归一化
主要模态 = $\arg \max_m |\Delta_m^{\text{cls}}|$

④ 关键证据与原始位置映射



③ 位置级遮蔽

文本: 单个词元位置, 步长 1
音频/视觉: 连续窗口 $W=5$, 步长 1
仅对已观测单元计算 Δ^{cls}
按 $|\Delta^{\text{cls}}|$ 降序取 Top-5 (对照 $K=3$)

⑤ 解释验证 (附件2 验证集, $n=728$)

忠实度
Top-K 片段
vs 等长随机片段
(随机重复 10 次)

稳定性
窗口平移 ± 1
输入扰动
 $\sigma \in \{0.01, 0.1, 0.5\}$

附件2 无时长/帧率字段: 音频、视觉只给桶位与相对位置;
附件4 带原始视频: 按有效跨度线性重建时间与帧号 (近似值)

贡献为相对遮蔽基线的边际效应, 不等同于因果贡献; 三模态贡献不可加; 时间与帧号为重建的近似位置;
全部结果基于单份冻结权重 (主种子 20260924), 不含跨训练种子的变化